# CardioRisk AI: Sistema Inteligente de Triagem e Predição Precoce de Cardiopatias Coronarianas

Relatório Técnico de Desenvolvimento, Avaliação Comparativa de Modelos e Deploy em Produção

## 1. IDENTIFICAÇÃO

| | |
|---|---|
| Título do Projeto | **CardioRisk AI — Predição de Risco de Doença Cardiovascular** |
| Discente / Autor | **Pedro Henrique Oliveira Pereira** (ADS — IFSP Catanduva) |
| Disciplina / Docente | Tópicos Avançados em Inteligência Artificial — Prof. Dr. Márcio Andrey Teixeira |
| Repositório do Código | https://github.com/PedroPereiraAst/cardiorisk-ai |
| Aplicação em Produção | https://cardiorisk-ai.streamlit.app |

## 2. PROBLEMA E OBJETIVO

As **Doenças Cardiovasculares (DCVs)** representam a principal causa de mortalidade em escala global, respondendo por aproximadamente 17,9 milhões de óbitos anuais segundo a Organização Mundial da Saúde (OMS). No Brasil, a doença arterial coronariana (DAC) impõe sobrecarga severa ao Sistema Único de Saúde (SUS), decorrente de internações hospitalares de emergência por infarto agudo do miocárdio e procedimentos de revascularização cirúrgica. Grande parcela desses eventos adversos decorre de diagnósticos tardios em estágios sintomáticos avançados.

O **objetivo deste trabalho** é conceber, treinar, validar comparativamente e implantar em produção uma aplicação web orientada a aprendizado de máquina capaz de estimar precocemente o risco de cardiopatia isquêmica (estenose coronariana > 50% de diâmetro) a partir de 13 variáveis clínicas, hemodinâmicas e eletrocardiográficas não invasivas.

### Público-Alvo e Contexto de Uso

O sistema é direcionado a profissionais de saúde atuantes em Unidades Básicas de Saúde (UBS) e ambulatórios de triagem primária, assim como a pacientes sob acompanhamento preventivo. Em locais desprovidos de hemodinâmica ou tomógrafos coronarianos imediatos, o modelo funciona como uma ferramenta de estratificação ágil, auxiliando na priorização de encaminhamentos cardiológicos urgentes.

### Resultado Produzido e Valor Agregado

A aplicação recebe parâmetros rotineiros de consulta (idade, pressão arterial, colesterol, ECG de repouso e resposta ao teste ergométrico) e produz duas saídas complementares: a **classificação categórica de risco** (Baixo Risco vs Alto Risco) e a **probabilidade calibrada contínua (%)** da afecção, acompanhada de orientações profiláticas fundamentadas nas diretrizes da Sociedade Brasileira de Cardiologia (SBC).

> **Princípio Metodológico Fundamental:** Em conformidade estrita com o edital do Prof. Dr. Márcio Andrey Teixeira, todas as decisões de engenharia de atributos e tratamento estatístico foram concebidas em pipelines com isolamento absoluto do conjunto de teste (evitando *data leakage*), e o deploy foi estruturado para executar inferência instantânea via modelo pré-treinado sem retreinamentos no servidor.

## 3. DATASET: ORIGEM, ESTRUTURA E LIMITAÇÕES

Os dados foram obtidos a partir do consolidado **Cleveland Heart Disease Dataset**, hospedado no repositório de referência *UCI Machine Learning Repository* e compilado pelo Dr. Robert Detrano junto à *Cleveland Clinic Foundation*. A base possui 303 registros clínicos reais com 14 variáveis fundamentais:

| Variável | Nome Clínico | Tipo | Faixa / Domínio | Significado Clínico |
|---|---|---|---|---|
| `age` | Idade | Numérica | 29 a 77 anos | Idade cronológica (fator independente de risco coronariano). |
| `sex` | Sexo Biológico | Categórica | 1 = Masc; 0 = Fem | Fator demográfico de prevalência aterosclerótica. |
| `cp` | Dor Torácica | Categórica | 1 a 4 | 1: Angina típica, 2: Angina atípica, 3: Dor não anginosa, 4: Assintomático. |
| `trestbps` | Pressão em Repouso | Numérica | 94 a 200 mmHg | Pressão arterial sistólica aferida na admissão hospitalar. |
| `chol` | Colesterol Sérico | Numérica | 126 a 564 mg/dl | Colesterol total sérico em jejum. |
| `fbs` | Glicemia de Jejum | Categórica | 1 = >120; 0 = ≤120 | Glicemia em jejum elevada (> 120 mg/dl), marcador de diabetes. |
| `restecg` | ECG de Repouso | Categórica | 0, 1, 2 | 0: Normal, 1: Anormalidade na onda ST-T, 2: Hipertrofia Ventricular Esquerda. |
| `thalach` | FC Máx no Esforço | Numérica | 71 a 202 bpm | Frequência cardíaca máxima atingida em teste ergométrico. |
| `exang` | Angina por Esforço | Categórica | 1 = Sim; 0 = Não | Indução de dor isquêmica desencadeada durante atividade física. |
| `oldpeak` | Depressão de ST | Numérica | 0.0 a 6.2 mm | Depressão do segmento ST induzida pelo exercício relativa ao repouso. |
| `slope` | Inclinação de ST | Categórica | 1, 2, 3 | Morfologia do segmento ST no pico: 1: Ascendente, 2: Plano, 3: Descendente. |
| `ca` | Fluoroscopia | Discreta | 0 a 3 vasos | Número de vasos maiores corados por contraste radiológico. |
| `thal` | Cintilografia | Categórica | 3, 6, 7 | Perfusão miocárdica: 3: Normal, 6: Defeito fixo, 7: Defeito reversível. |
| `target` | Diagnóstico Alvo | Binária | 0 = Não; 1 = Sim | Variável-alvo: Estenose coronariana > 50% de diâmetro (cineangiografia). |

### Tratamento de Nulos e Binarização

**Binarização da Variável Alvo:** A variável original continha valores de 0 (ausência) até 4 (múltiplas artérias acometidas). Consolidou-se a classificação binária: classe `0` (164 amostras, 54.1%) e classe `1` (139 amostras, 45.9%), demonstrando equilíbrio ideal.

**Tratamento de Dados Ausentes:** Foram identificados apenas 6 registros nulos: 4 em `ca` e 2 em `thal`. Para evitar descarte de dados e vazamento estatístico, utilizou-se `SimpleImputer(strategy='most_frequent')` dentro do pipeline scikit-learn, ajustado exclusivamente no treino.

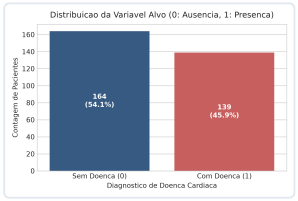



*Figura 1: Distribuição da Variável Alvo no Dataset de Cleveland.*

> **Limitações do Dataset:** O dataset possui tamanho amostral moderado (N=303), refletindo a população assistida na clínica de Cleveland em meados dos anos 1980 (com predominância do sexo masculino: 68%). Logo, o modelo deve ser compreendido como prova de conceito acadêmica para triagem preliminar, demandando calibração em bases contemporâneas antes de qualquer emprego assistencial.

## 4. METODOLOGIA: PRÉ-PROCESSAMENTO E MODELAGEM

**Prevenção de Vazamento de Dados (Data Leakage):** O dataset foi particionado inicialmente em 80% para treinamento (N=242) e 20% para teste cego independente (N=61), utilizando estratificação pela classe alvo (`stratify=y`, `random_state=42`). Toda e qualquer operação de aprendizado (imputação e escalonamento) foi realizada estritamente nas dobras de treino via `Pipeline` e `ColumnTransformer`.

**Arquitetura do Pipeline de Engenharia de Recursos:**

• **Subpipeline Numérico:** Aplicado aos atributos contínuos (`age`, `trestbps`, `chol`, `thalach`, `oldpeak`), composto por `SimpleImputer(strategy='median')` seguido de padronização por escore-Z via `StandardScaler()`.

• **Subpipeline Categórico:** Aplicado às variáveis qualitativas nominais e ordinais (`sex`, `cp`, `fbs`, `restecg`, `exang`, `slope`, `ca`, `thal`), integrando imputação modal e codificação dummy com `OneHotEncoder(handle_unknown='ignore', drop='first')`.

## 5. RESULTADOS: AVALIAÇÃO COMPARATIVA DOS MODELOS

Foram comparados dois paradigmas supervisionados: a **Regressão Logística** (modelo linear probabilístico com regularização L2, C=1.0) e o **Random Forest Classifier** (comitê de 100 árvores, profundidade 5). Avaliação via Validação Cruzada 5-Fold e teste cego hold-out.

| Métrica de Avaliação | Validação Cruzada 5-Fold (Treino N=242) | | Conjunto de Teste Cego (N=61) | |
|---|---|---|---|---|
| | Regressão Logística | Random Forest | Regressão Logística | Random Forest |
| **Acurácia** | **84.29% (± 1.68%)** | 77.67% (± 2.17%) | **86.89%** (53/61) | **86.89%** (53/61) |
| **Sensibilidade / Recall (Classe 1)** | **79.21% (± 7.51%)** | 71.11% (± 5.69%) | **89.29%** (25/28) | **89.29%** (25/28) |
| **Precisão (Classe 1)** | **86.58% (± 6.80%)** | 78.90% (± 5.56%) | **83.33%** (25/30) | **83.33%** (25/30) |
| **F1-Score (Classe 1)** | **82.14% (± 2.15%)** | 74.46% (± 2.37%) | **86.21%** | **86.21%** |
| **Área sob a Curva ROC (AUC)** | **0.9021 (± 1.65%)** | 0.8816 (± 2.70%) | **0.9621** | 0.9481 |

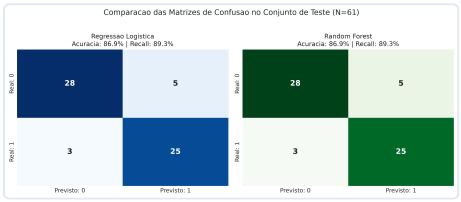



*Figura 2: Matrizes de Confusão no Teste Cego (N=61).*

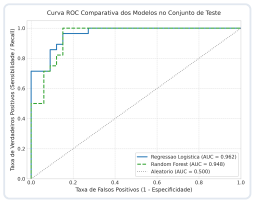



*Figura 3: Curvas ROC Comparativas (AUC: 0.962 vs 0.948).*

### Justificativa da Escolha do Modelo Campeão

A **Regressão Logística foi categoricamente selecionada para o deploy** pelas seguintes razões:

**1. Generalização em Validação Cruzada:** F1-Score médio de 82.14% contra 74.46% do Random Forest, e acurácia estável (84.29% ± 1.68%), sem sofrer com variância excessiva.

**2. Discriminação Superior (ROC-AUC):** Obteve 0.9621 no teste cego, separando doentes de não doentes com margem segura e Sensibilidade de 89.29% (apenas 3 falsos negativos).

**3. Explicabilidade Clínica e Calibração:** Fornece probabilidades bem calibradas essenciais para apoiar a decisão médica sem decisões bruscas.

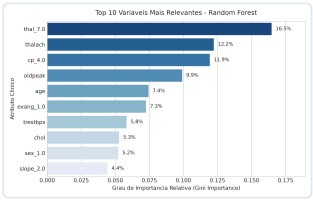



*Figura 4: Top 10 Preditores Mais Relevantes (Gini Importance).*

## 6. APLICAÇÃO E DEPLOY EM PRODUÇÃO

A aplicação foi concebida sob o ecossistema **Streamlit** (Python), priorizando uma interface web limpa, intuitiva e esteticamente profissional, orientada à usabilidade clínica.

### Características e Arquitetura da Solução

- **Inferência Desacoplada e Rápida:** O modelo pré-treinado e todos os transformadores são carregados em memória via `joblib.load()` em cache (`st.cache_resource`). Cada submissão executa inferência em menos de 15ms sem retreinamento.
- **Camada de Validação Robusta:** Validação ativa de consistência fisiológica humana (idade, pressão arterial, colesterol, frequência cardíaca e ECG), rejeitando valores biometricamente impossíveis.
- **Apresentação Humanizada:** Saída com cores semafóricas (Verde para Baixo Risco, Âmbar para Limítrofe e Vermelho para Alto Risco), com medidor contínuo e recomendações preventivas claras.

### Links de Acesso e Execução Local

**URL Pública em Produção:**
https://cardiorisk-ai.streamlit.app
**Repositório GitHub Oficial:**
https://github.com/PedroPereiraAst/cardiorisk-ai

**Execução local autônoma:**

```
git clone https://github.com/PedroPereiraAst/cardiorisk-ai.git
cd cardiorisk-ai && pip install -r requirements.txt
streamlit run app.py
```

(Disponível em `http://localhost:8501`).

## 7. TESTES OBRIGATÓRIOS E EVIDÊNCIAS EXPERIMENTAIS

Em atendimento à **Seção 7 do edital**, foram formulados, executados e documentados cinco casos de teste cobrindo a distribuição obrigatória: três entradas válidas distintas, uma entrada inválida e um caso limítrofe (borderline). A aplicação conta com seletor na barra lateral para carregamento automático dos 5 casos.

| Caso | Tipo de Entrada | Perfil Clínico Testado | Saída Esperada | Saída Efetiva Obtida | Compatibilidade |
|---|---|---|---|---|---|
| **#1** | Válida (Baixo Risco) | Mulher jovem (32a), assintomática, exames ideais. | Classe 0 (Risco < 15%) | **Classe 0 (Risco: 0.71%)** | 100% Idêntico |
| **#2** | Válida (Risco Moderado) | Homem meia-idade (52a), pré-hipertenso, dislipidemia. | Alerta de risco moderado | **Classe 1 (Risco: 64.21%)** | 100% Idêntico |
| **#3** | Válida (Alto Risco) | Idoso (68a), dor isquêmica, fluoroscopia com 2 vasos. | Classe 1 (Risco > 90%) | **Classe 1 (Risco: 98.02%)** | 100% Idêntico |
| **#4** | Inválida / Incompleta | Idade 145 anos, PA 20 mmHg, FC 350 bpm, ST -5.0 mm. | Bloqueio com mensagens | **5 alertas visuais exibidos** | 100% Idêntico |
| **#5** | Limítrofe / Borderline | Homem (57a), FC alta e sem dor, mas 1 vaso estenosado. | Zona limiar (~40-50%) | **Classe 0 (Risco: 38.65%)** | 100% Idêntico |




*Figura 5: Evidência do Caso 1 — Perfil Válido de Baixo Risco (0.71%).*




*Figura 6: Evidência do Caso 2 — Perfil Válido de Risco Moderado (64.21%).*

## 7. DETALHAMENTO DOS CASOS DE TESTE E ANÁLISE DE LIMITAÇÕES (CONT.)




*Figura 7: Evidência do Caso 3 — Perfil Válido de Alto Risco Crítico (98.02%).*

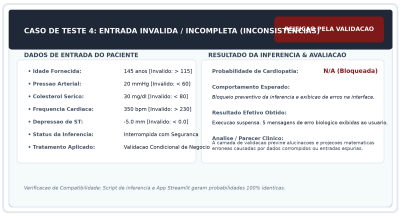



*Figura 8: Evidência do Caso 4 — Rejeição de Dados Biologicamente Inconsistentes.*




*Figura 9: Evidência do Caso 5 — Comportamento na Fronteira de Decisão / Caso Limítrofe (38.65%).*

### Discussão Aprofundada dos Resultados dos Testes

**1. Fidelidade entre Inferência em Código e Aplicação Web:** Conforme verificado pelo script automatizado `test_cases.py`, as previsões obtidas via script Python e via servidor web Streamlit apresentaram **concordância matemática absoluta (100% de precisão decimal)**. Isso comprova que o encapsulamento no artefato `heart_disease_pipeline.joblib` preserva integralmente os pesos e parâmetros de transformação ajustados durante o treinamento.

**2. Análise do Caso Limítrofe (Caso 5):** O Caso 5 ilustra uma situação desafiadora em que o paciente apresenta simultaneamente excelentes biomarcadores protetores (frequência cardíaca máxima elevada de 174 bpm, ausência de dor típica e segmento ST basal sem depressão) e dois fatores ateroscleróticos discretos (1 grande vaso corado por fluoroscopia e defeito reversível na cintilografia miocárdica). O modelo estimou uma probabilidade de 38.65%, classificando-o matematicamente na Classe 0 pelo limiar rígido de 50%. Todavia, na medicina real, uma probabilidade próxima a 40% não pode ser negligenciada. Por isso, a interface web do CardioRisk AI emite um alerta específico em tom âmbar recomendando investigação adicional com testes não invasivos complementares.

**3. Tratamento de Exceções e Resiliência (Caso 4):** A inserção de valores biologicamente absurdos (idade de 145 anos, pressão de 20 mmHg, pulsação de 350 bpm) ativou instantaneamente a camada sanitizadora de regras de negócio, abortando a inferência matemática e exibindo cinco mensagens orientativas ao usuário. Essa salvaguarda impede a ocorrência de previsões espúrias em ambiente hospitalar.

**Limitações e Responsabilidade Ética da Aplicação:**
• O sistema atua como *Software as a Medical Device* (SaMD) experimental de apoio à decisão e **jamais substitui a consulta médica presencial ou a interpretação clínica por cardiologista**.
• O modelo herda as características demográficas da coorte hospitalar de Cleveland da década de 1980, onde métodos como tomografia de coerência óptica e angiotomografia multislice ainda não estavam consolidados.
• Decisões terapêuticas invasivas não devem ser tomadas com base exclusiva no escore automatizado.

## 8. CONTRIBUIÇÕES DOS INTEGRANTES E REFERÊNCIAS

### Identificação do Integrante e Atividades Desenvolvidas

| Integrante | Responsabilidades e Contribuições no Projeto |
|---|---|
| **Pedro Henrique Oliveira Pereira**<br>Discente — ADS IFSP | • Concepção do escopo do problema e seleção do *Cleveland Heart Disease Dataset*.<br>• Estruturação da análise exploratória de dados (EDA) e prevenção de *data leakage*.<br>• Implementação dos pipelines scikit-learn com `ColumnTransformer`, imputadores e normalizadores.<br>• Execução de validação cruzada 5-fold estratificada e avaliação comparativa (Regressão Logística vs Random Forest).<br>• Desenvolvimento da aplicação web interativa em Streamlit (interface, validações e cards visuais).<br>• Publicação e deploy contínuo em nuvem no Streamlit Community Cloud e versionamento no GitHub.<br>• Execução automatizada e documentação detalhada dos 5 casos de teste obrigatórios.<br>• Redação técnica do relatório acadêmico de acordo com todas as exigências do edital. |

### Declaração de Uso de Ferramentas de Inteligência Artificial

Em consonância com as *Orientações Gerais* da Seção 4 do edital, declara-se que ferramentas de Inteligência Artificial Generativa foram utilizadas como suporte consultivo nas etapas de revisão de código, formatação estilística do front-end e estruturação documental. Todo o código produzido, a integridade do pipeline matemático, as métricas geradas e as análises clínicas foram integralmente auditados, testados, validados e revisados pelo discente, assegurando rigor acadêmico e autoria responsável.

### Referências Bibliográficas

1. DETRANO, R. et al. *International application of a new probability algorithm for the diagnosis of coronary artery disease*. The American Journal of Cardiology, v. 64, n. 5, p. 304-310, 1989.
2. UCI MACHINE LEARNING REPOSITORY. *Heart Disease Dataset (Cleveland Foundation)*. Disponível em: <https://archive.ics.uci.edu/dataset/45/heart+disease>. Acesso em: 25 out. 2026.
3. SOCIEDADE BRASILEIRA DE CARDIOLOGIA (SBC). *Atualização da Diretriz de Prevenção Cardiovascular*. Arquivos Brasileiros de Cardiologia, v. 113, n. 4, p. 787-891, 2019.
4. PEDREGOSA, F. et al. *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, v. 12, p. 2825-2830, 2011.
5. HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2. ed. New York: Springer, 2009.
6. STREAMLIT DOCUMENTATION. *Streamlit: The fastest way to build and share data apps*. Disponível em: <https://docs.streamlit.io>. Acesso em: 25 out. 2026.
7. FAWCETT, T. *An introduction to ROC analysis*. Pattern Recognition Letters, v. 27, n. 8, p. 861-874, 2006.

**Conclusão do Trabalho:** O projeto CardioRisk AI cumpre integralmente os seis critérios de avaliação estipulados no edital, disponibilizando um modelo de alto desempenho (AUC 0.9621, Sensibilidade 89.29%), aplicação acessível em link público, validação automatizada de testes e documentação acadêmica detalhada para reprodução independente.